Econometrics II
Problem Set 2

Part I – Analytical Questions

Question 1

Consider the ARMA(2,1) process:

$$y_t = 0.4 + 0.9y_{t-1} - 0.3y_{t-2} + \varepsilon_t + 0.5\varepsilon_{t-1}, \quad t = 1, \ldots, 300 \tag{1}$$

$$\varepsilon_t \sim \text{Gaussian } WN(0, \sigma_\varepsilon^2)$$

(a) Find the one to three-step forecast of y_t.

Usando la media condicional $\hat{y}_{t+j} = E[y_{t+j} \mid \Omega_t]$:

Forecast 1

$$y_{301} = 0.4 + 0.9y_{300} - 0.3y_{299} + \varepsilon_{301} + 0.5\varepsilon_{300}$$
$$E[y_{301} \mid \Omega_{300}] = E[0.4 \mid \Omega_{300}] + E[0.9y_{300} \mid \Omega_{300}] - E[0.3y_{299} \mid \Omega_{300}] + E[\varepsilon_{301} \mid \Omega_{300}] + E[0.5\varepsilon_{300} \mid \Omega_{300}]$$
$$\hat{y}_{301} = 0.4 + 0.9y_{300} - 0.3y_{299} + 0 + 0.5\varepsilon_{300}$$

Nota: ε_{301} tiene esperanza cero, pero ε_{300} no, ya que en el momento t ya conocemos el valor realizado de ε_{t-1}, mientras que ε_t aún no ha ocurrido, por lo que $E[\varepsilon_t] = 0$ dado que $\varepsilon_t \sim WN(0, \sigma_\varepsilon^2)$.

Forecast 2

$$y_{302} = 0.4 + 0.9y_{301} - 0.3y_{300} + \varepsilon_{302} + 0.5\varepsilon_{301}$$
$$E[y_{302} \mid \Omega_{300}] = E[0.4 \mid \Omega_{300}] + E[0.9y_{301} \mid \Omega_{300}] - E[0.3y_{300} \mid \Omega_{300}] + E[\varepsilon_{302} \mid \Omega_{300}] + E[0.5\varepsilon_{301} \mid \Omega_{300}]$$
$$\hat{y}_{302} = 0.4 + 0.9y_{301} - 0.3y_{300} + 0 + 0$$

Tanto ε_{301} como ε_{302} son desconocidos aquí, por lo que recurrimos a $\varepsilon_t \sim WN(0, \sigma_\varepsilon^2)$
Sustituyendo y_{301} por $\hat{y}_{301}$:

$$\begin{aligned}\hat{y}_{302} &= 0.4 + 0.9\left(0.4 + 0.9y_{300} - 0.3y_{299} + 0.5\varepsilon_{300}\right) - 0.3y_{300} \\ &= 0.4 + (0.36 + 0.81y_{300} - 0.27y_{299} + 0.45\varepsilon_{300}) - 0.3y_{300} \\ &= 0.76 + 0.51y_{300} - 0.27y_{299} + 0.45\varepsilon_{300}\end{aligned}$$

Forecast 3

$$y_{303} = 0.4 + 0.9y_{302} - 0.3y_{301} + \varepsilon_{303} + 0.5\varepsilon_{302}$$
$$\hat{y}_{303} = 0.4 + 0.9y_{302} - 0.3y_{301}$$

Sustituyendo y_{301} y y_{302} por $\hat{y}_{301}, \hat{y}_{302}$:

$$\begin{aligned}\hat{y}_{303} &= 0.4 + 0.9\left(0.76 + 0.51y_{300} - 0.27y_{299} + 0.45\varepsilon_{300}\right) - 0.3\left(0.4 + 0.9y_{300} - 0.3y_{299} + 0.5\varepsilon_{300}\right) \\ &= 0.4 + (0.684 + 0.459y_{300} - 0.243y_{299} + 0.405\varepsilon_{300}) - (0.12 + 0.27y_{300} - 0.09y_{299} + 0.15\varepsilon_{300}) \\ &= 0.964 + 0.189y_{300} - 0.153y_{299} + 0.255\varepsilon_{300}\end{aligned}$$

Resumen

$$\hat{y}_{301} = 0.4 + 0.9y_{300} - 0.3y_{299} + 0.5\varepsilon_{300} \quad (1)$$
$$\hat{y}_{302} = 0.76 + 0.51y_{300} - 0.27y_{299} + 0.45\varepsilon_{300} \quad (2)$$
$$\hat{y}_{303} = 0.964 + 0.189y_{300} - 0.153y_{299} + 0.255\varepsilon_{300} \quad (3)$$

(b) Determine the variance of the one to three-step forecast and provide a 95% confidence interval for the prediction at $t = 301, 302, 303$. Assume $\sigma_\varepsilon^2 = 1.5$.

Forecast 1

$$y_{301} = 0.4 + 0.9y_{300} - 0.3y_{299} + \varepsilon_{301} + 0.5\varepsilon_{300}$$
$$\hat{y}_{301} = 0.4 + 0.9y_{300} - 0.3y_{299} + 0 + 0.5\varepsilon_{300}$$

Error de Forecast: $e_{301} = y_{301} - \hat{y}_{301} = \varepsilon_{301}$

$$V(e_{301}) = \sigma_\varepsilon^2 = 1.5$$

Forecast 2

$$y_{302} = 0.4 + 0.9y_{301} - 0.3y_{300} + \varepsilon_{302} + 0.5\varepsilon_{301}$$
$$\hat{y}_{302} = 0.4 + 0.9\hat{y}_{301} - 0.3y_{300}$$

$$e_{302} = y_{302} - \hat{y}_{302} = 0.9(y_{301} - \hat{y}_{301}) + \varepsilon_{302} + 0.5\varepsilon_{301} = 0.9\varepsilon_{301} + \varepsilon_{302} + 0.5\varepsilon_{301}$$
$$e_{302} = \varepsilon_{302} + 1.4\varepsilon_{301}$$
$$V(e_{302}) = V(\varepsilon_{302}) + 1.4^2 V(\varepsilon_{301}) = 1.5 + (1.4)^2(1.5) = 1.5(1 + 1.96) = 4.44$$

Forecast 3

$$y_{303} = 0.4 + 0.9y_{302} - 0.3y_{301} + \varepsilon_{303} + 0.5\varepsilon_{302}$$
$$\hat{y}_{303} = 0.4 + 0.9\hat{y}_{302} - 0.3\hat{y}_{301}$$

$$e_{303} = 0.9(y_{302} - \hat{y}_{302}) - 0.3(y_{301} - \hat{y}_{301}) + \varepsilon_{303} + 0.5\varepsilon_{302} = 0.9e_{302} - 0.3e_{301} + \varepsilon_{303} + 0.5\varepsilon_{302}$$
$$= 0.9\left(\varepsilon_{302} + 1.4\varepsilon_{301}\right) - 0.3\varepsilon_{301} + \varepsilon_{303} + 0.5\varepsilon_{302}$$
$$= \varepsilon_{303} + (0.9 + 0.5)\varepsilon_{302} + (1.26 - 0.3)\varepsilon_{301}$$
$$= \varepsilon_{303} + 1.4\varepsilon_{302} + 0.96\varepsilon_{301}$$

$$V(e_{303}) = \sigma_\varepsilon^2\left(1^2 + 1.4^2 + 0.96^2\right) = 1.5(3.8816) = 5.8224$$

Intervalos de confianza al 95%

$$CI_{95\%} = \hat{y} \pm 1.96\sqrt{V(e)}$$
$$\hat{y}_{301} \pm 1.96\sqrt{1.5} = \hat{y}_{301} \pm 2.400$$
$$\hat{y}_{302} \pm 1.96\sqrt{4.44} = \hat{y}_{302} \pm 4.130$$
$$\hat{y}_{303} \pm 1.96\sqrt{5.8224} = \hat{y}_{303} \pm 4.729$$

Question 2

Consider the processes:

$$y_t = 0.3 + 1.4y_{t-1} - 0.4y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2} \tag{2}$$
$$y_t = 2y_{t-1} - y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1} \tag{3}$$
$$y_t = 0.9 + 1.3y_{t-1} - 0.42y_{t-2} + \varepsilon_t - 1.4\varepsilon_{t-1} + 0.48\varepsilon_{t-2} \tag{4}$$

(a) Write these as ARIMA(p, d, q) processes identifying the values of p, d and q.

Proceso general

Primero expresamos el proceso utilizando lag operators, después utilizando estas podemos ver que (p, d, q) se identifican de la siguiente manera:

- d: Número de raíces unitarias ($L = 1$).
- p: Número de raíces AR estacionarias restantes ($|L| > 1$).
- q: Orden del polinomio MA $\Theta(L)$. (no cambia)

Es importante notar que esto funciona para el polinomio característico AR de orden 2 o menor, ya que encontrar las raíces de un polinomio de orden 3 requeriría el uso de métodos computacionales.

Proceso (2)

$$y_t = 0.3 + 1.4y_{t-1} - 0.4y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2}$$

Agrupando términos en notación de lags:

$$(1 - 1.4L + 0.4L^2)y_t = 0.3 + (1 - 0.7L + 0.12L^2)\varepsilon_t$$

Igualando el polinomio AR a cero: $0.4L^2 - 1.4L + 1 = 0$

$$L = \frac{-(-1.4) \pm \sqrt{(-1.4)^2 - 4(0.4)(1)}}{2(0.4)} = \frac{1.4 \pm \sqrt{1.96 - 1.6}}{0.8} = \frac{1.4 \pm \sqrt{0.36}}{0.8}$$

$$L_1 = \frac{1.4 - 0.6}{0.8} = 1, \qquad L_2 = \frac{1.4 + 0.6}{0.8} = 2.5$$

Evaluando las raíces:

- $L_1 = 1 \implies$ Exactamente $d = 1$ raíz unitaria.
- $|L_2| = 2.5 > 1 \implies$ Componente AR estacionario restante de orden $p = 1$.
- $\Theta(L) = 1 - 0.7L + 0.12L^2 \implies$ Componente MA de orden $q = 2$.

$$y_t \sim ARIMA(1, 1, 2)$$

Proceso (3)

$$y_t = 2y_{t-1} - y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1}$$

Agrupando términos en notación de lags:

$$(1 - 2L + L^2)y_t = (1 - 0.7L)\varepsilon_t$$

Igualando el polinomio AR a cero: $L^2 - 2L + 1 = 0$:

$$L = \frac{-(-2) \pm \sqrt{(-2)^2 - 4(1)(1)}}{2(1)} = \frac{2 \pm \sqrt{4-4}}{2} = \frac{2 \pm 0}{2}$$

$$L_1 = 1, \qquad L_2 = 1$$

Evaluando las raíces:

- $L_1 = L_2 = 1 \implies$ Raíz unitaria doble, por lo que $d = 2$.
- No queda factor AR estacionario $\implies p = 0$.
- $\Theta(L) = 1 - 0.7L \implies$ Componente MA de orden $q = 1$.

$$y_t \sim ARIMA(0, 2, 1)$$

Proceso (4)

$$y_t = 0.9 + 1.3y_{t-1} - 0.42y_{t-2} + \varepsilon_t - 1.4\varepsilon_{t-1} + 0.48\varepsilon_{t-2}$$

Agrupando términos en notación de lags:

$$(1 - 1.3L + 0.42L^2)y_t = 0.9 + (1 - 1.4L + 0.48L^2)\varepsilon_t$$

Igualando el polinomio AR a cero: $0.42L^2 - 1.3L + 1 = 0$:

$$L = \frac{-(-1.3) \pm \sqrt{(-1.3)^2 - 4(0.42)(1)}}{2(0.42)} = \frac{1.3 \pm \sqrt{1.69 - 1.68}}{0.84} = \frac{1.3 \pm \sqrt{0.01}}{0.84}$$

$$L_1 = \frac{1.3 - 0.1}{0.84} = \frac{1.2}{0.84} \approx 1.4286, \qquad L_2 = \frac{1.3 + 0.1}{0.84} = \frac{1.4}{0.84} \approx 1.6667$$

Evaluando las raíces:

- Ambas raíces satisfacen $|L_i| > 1 \implies$ No hay raíces unitarias ($d = 0$), el proceso es estacionario en niveles.
- Grado del polinomio AR $\implies p = 2$.
- $\Theta(L) = 1 - 1.4L + 0.48L^2 \implies$ Componente MA de orden $q = 2$.

$$y_t \sim ARIMA(2, 0, 2)$$

(b) Make the necessary transformation to obtain stationary processes.

Dado que verificamos la estacionariedad en el ítem a), podemos proceder a transformar el proceso para hacerlo estacionario

Proceso (2)

$$y_t - y_{t-1} = 0.3 + 1.4y_{t-1} - y_{t-1} - 0.4y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2}$$
$$\Delta y_t = 0.3 + 0.4y_{t-1} - 0.4y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2}$$
$$\Delta y_t = 0.3 + 0.4(y_{t-1} - y_{t-2}) + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2}$$
$$\Delta y_t = 0.3 + 0.4\Delta y_{t-1} + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2}$$

Verificando la estacionariedad del proceso diferenciado:

$$\Delta y_t(1 - 0.4L) \;\Rightarrow\; \Phi(L) = 1 - 0.4L = 0$$
$$|L| = \left|\tfrac{1}{0.4}\right| = 2.5 > 1$$

Ahora es estacionario. La representación transformada y estacionaria es:

$$\Delta y_t = 0.3 + 0.4\Delta y_{t-1} + \varepsilon_t - 0.7\varepsilon_{t-1} + 0.12\varepsilon_{t-2} \sim ARIMA(1, 1, 2)$$

Proceso (3)

Primera diferencia:

$$\Delta y_t = 2y_{t-1} - y_{t-1} - y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1}$$
$$\Delta y_t = y_{t-1} + y_{t-2} + \varepsilon_t - 0.7\varepsilon_{t-1}$$
$$\Delta y_t = \Delta y_{t-1} + \varepsilon_t - 0.7\varepsilon_{t-1}$$

Verificar estacionariedad:

$$\Delta y_t(1 - L) \qquad \Phi(L) = (1 - L) = 0$$
$$|L| = 1 \quad \text{aún no estacionario}$$

Segunda diferencia:

$$\Delta y_t - \Delta y_{t-1} = \Delta y_{t-1} - \Delta y_{t-1} + \varepsilon_t - 0.7\varepsilon_{t-2}$$
$$\Delta^2 y_t = \varepsilon_t - 0.7\varepsilon_{t-1}$$

Este es un proceso MA puro, por lo tanto es estacionario por construcción, no hay raíces que verificar. La representación transformada y estacionaria es:

$$\Delta^2 y_t = \varepsilon_t - 0.7\varepsilon_{t-1} \sim ARIMA(0, 2, 1)$$

Proceso (4)

No se requiere transformación: dado que ambas raíces características satisfacen $|L_i| > 1$, el proceso ya es estacionario en niveles.

$$y_t = 0.9 + 1.3y_{t-1} - 0.42y_{t-2} + \varepsilon_t - 1.4\varepsilon_{t-1} + 0.48\varepsilon_{t-2} \sim ARIMA(2, 0, 2)$$

Question 3

Consider the process:

$$y_t = y_{t-1} + \varepsilon_t + 0.3\varepsilon_{t-1} - 0.2\varepsilon_{t-2} \tag{5}$$
$$\varepsilon_t \sim \text{Gaussian } WN(0, \sigma_\varepsilon^2)$$

Show that the variance of the prediction of $\hat{y}_{t+h}$ goes to infinity when h goes to infinity.

Paso 1: identificar el proceso

Escribiendo el modelo en términos del operador de lags:

$$y_t - y_{t-1} = \varepsilon_t + 0.3\varepsilon_{t-1} - 0.2\varepsilon_{t-2}$$
$$(1-L)y_t = \Theta(L)\varepsilon_t, \qquad \Theta(L) = 1 + 0.3L - 0.2L^2$$

Como $\Phi(L) = 1-L$ tiene una raíz unitaria ($L = 1$), el proceso no es estacionario. Diferenciando una vez:

$$\Delta y_t = \varepsilon_t + 0.3\varepsilon_{t-1} - 0.2\varepsilon_{t-2} \;\sim\; MA(2) \quad \Rightarrow \quad y_t \sim ARIMA(0,1,2)$$

Δy_t es un proceso MA finito, por lo tanto estacionario. Nótese que $\Theta(1) = 1+0.3-0.2 = 1.1 \neq 0$, es decir, el polinomio MA *no* cancela la raíz unitaria: esto es lo que genera el resultado que sigue.

Paso 2: telescopiar el nivel h períodos hacia adelante Como $\Delta y_{t+j} = y_{t+j} - y_{t+j-1}$, al sumar sobre $j = 1, \ldots, h$ se obtiene una suma telescópica en la que se cancelan todos los términos intermedios:

$$\sum_{j=1}^{h} \Delta y_{t+j} = (y_{t+1} - y_t) + (y_{t+2} - y_{t+1}) + \cdots + (y_{t+h} - y_{t+h-1}) = y_{t+h} - y_t$$

Por ende:

$$y_{t+h} = y_t + \sum_{j=1}^{h} \Delta y_{t+j} = y_t + \sum_{j=1}^{h} (\varepsilon_{t+j} + 0.3\varepsilon_{t+j-1} - 0.2\varepsilon_{t+j-2})$$

Paso 3: forecast y error del forecast El forecast óptimo es la media condicional $\hat{y}_{t+h} = E[y_{t+h} \mid \Omega_t]$. Todos los shocks en $t+i$ con $i \geq 1$ son desconocidos y cumplen $E[\varepsilon_{t+i} \mid \Omega_t] = 0$, mientras que y_t, ε_t y ε_{t-1} ya se conocen en t. El error de forecast es entonces la suma de las innovaciones futuras únicamente:

$$e_t(h) = y_{t+h} - \hat{y}_{t+h} = \sum_{i=1}^{h} \psi_i^{(h)} \varepsilon_{t+i}$$

Para encontrar los ponderadores $\psi_i^{(h)}$, notemos que un shock dado ε_{t+i} entra tres veces en la doble suma: en el término $j = i$ con peso 1, en $j = i+1$ con peso 0.3 y en $j = i+2$ con peso

-0.2, siempre que esos índices no superen h. Luego, para $h \geq 3$:

$$\begin{aligned} \varepsilon_{t+h}: &\quad \psi = 1 \\ \varepsilon_{t+h-1}: &\quad \psi = 1 + 0.3 = 1.3 \\ \varepsilon_{t+i},\ i \leq h-2: &\quad \psi = 1 + 0.3 - 0.2 = 1.1 = \Theta(1) \end{aligned}$$

de modo que

$$e_t(h) = \varepsilon_{t+h} + 1.3\,\varepsilon_{t+h-1} + 1.1 \sum_{i=1}^{h-2} \varepsilon_{t+i}$$

Paso 4: varianza del error de forecast Como $\varepsilon_t \sim WN(0, \sigma_\varepsilon^2)$, los socks no están correlacionados y tienen varianza común σ_ε^2, por lo que la varianza es la suma de los ponderadores al cuadrado.

$$V[e_t(h)] = \sigma_\varepsilon^2 \sum_{i=1}^{h} \left(\psi_i^{(h)}\right)^2 = \sigma_\varepsilon^2 \left[1^2 + 1.3^2 + (h-2)(1.1)^2\right]$$

$$V[e_t(h)] = \sigma_\varepsilon^2 \left[1 + 1.69 + 1.21(h-2)\right] = \sigma_\varepsilon^2 \left(1.21\,h + 0.27\right), \qquad h \geq 2$$

Por ende, dado que $\hat{y}_{t+h}$ es conocido en t, la varianza condicional de y_{t+h} coincide con la del error de predicción:

$$V[y_{t+h} \mid \Omega_t] = V[e_t(h)] = \sigma_\varepsilon^2 \left(1.21\,h + 0.27\right) \xrightarrow[h \to \infty]{} \infty$$

La incertidumbre sobre el nivel futuro de la serie crece a infinito, lo que refleja que y_t no es estacionario y que su varianza incondicional no está definida.

Part II – Empirical Question

Question 4

a)

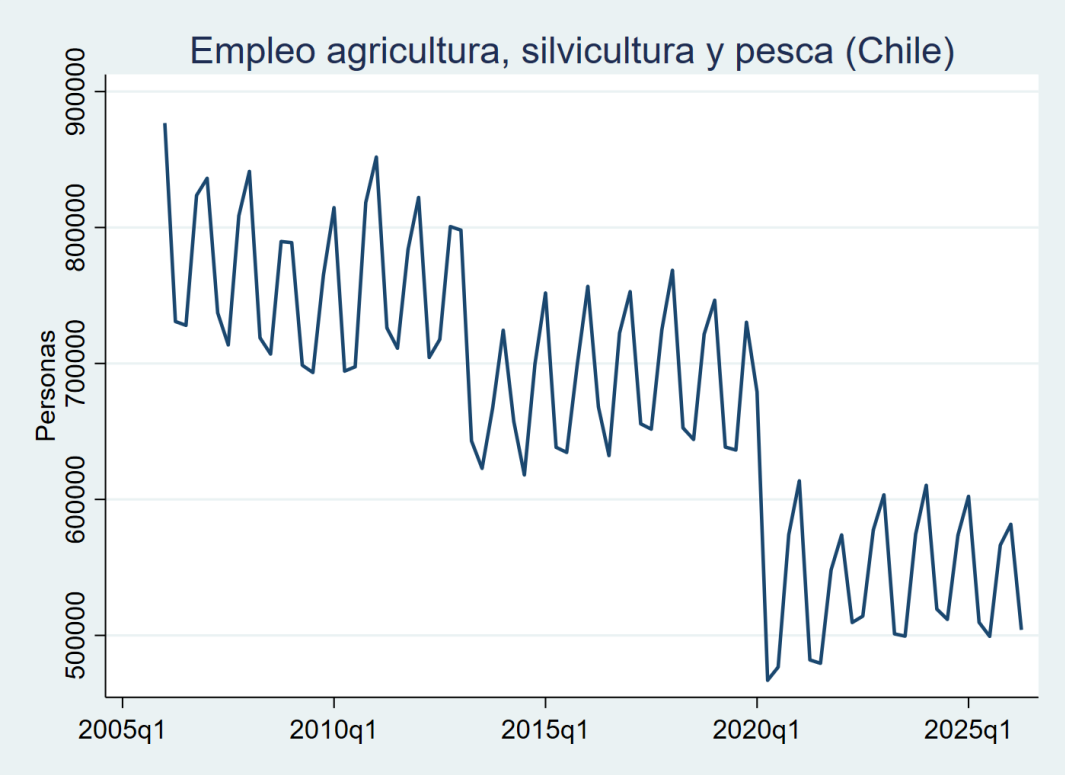


Figure 1: Empleo en agricultura, silvicultura y pesca. Chile, 2006q1–2026q2.

El primer trimestre (verano, cosecha) es sistemáticamente el máximo del año y el segundo y tercero (invierno) los mínimos. Se aprecian dos caídas abruptas de nivel, en torno a 2013q2 y a 2020q2. La serie no describe una tendencia descendente continua sino una sucesión de mesetas.

La metodología de Box-Jenkins consta de tres etapas: identificación, estimación y chequeo de diagnóstico.

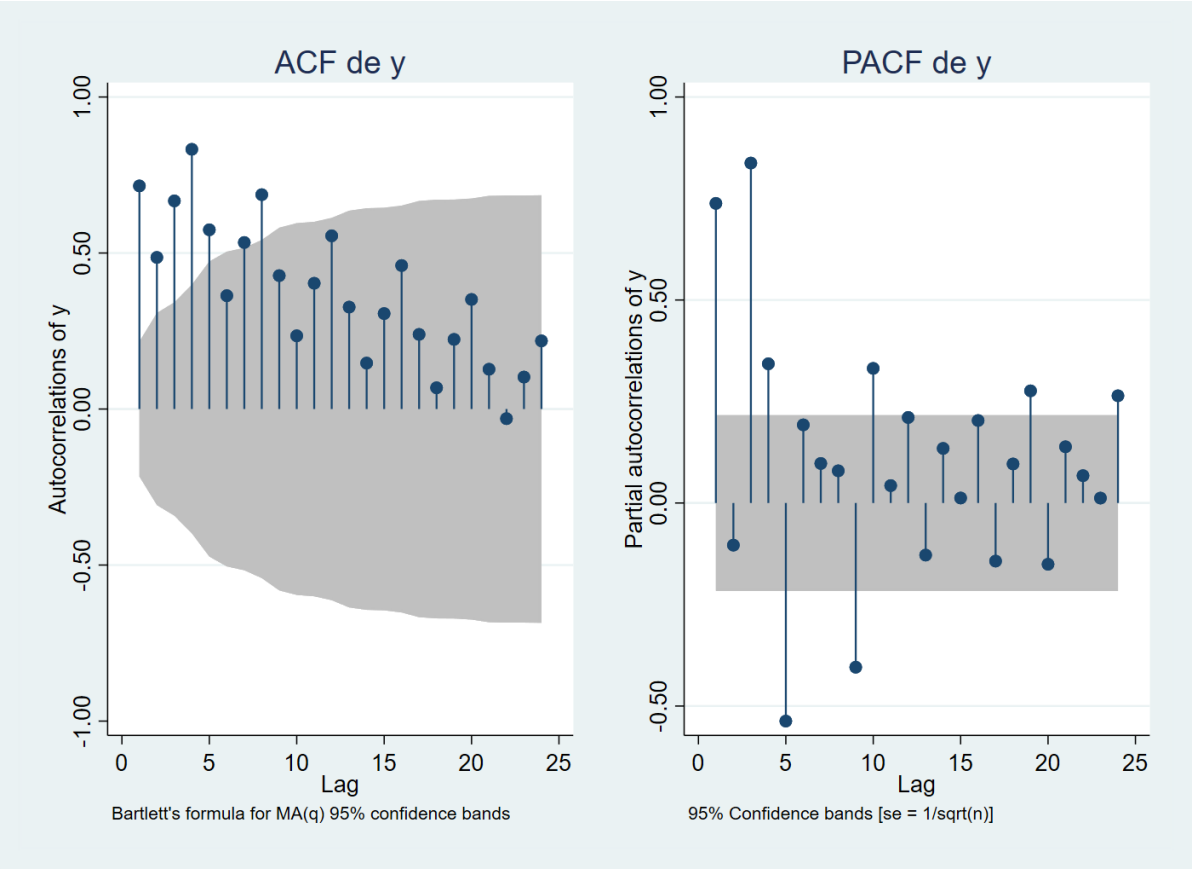


Figure 2: ACF y PACF de y_t en niveles.

La ACF decae muy lentamente y conserva picos locales en los múltiplos de 4, lo que es la firma conjunta de una raíz unitaria y de estacionalidad. Para formalizar el diagnóstico se aplica el test de Dickey–Fuller aumentado en la regresión anidada vista en clases,

$$\Delta y_t \;=\; \mu + \beta t + \gamma\, y_{t-1} + \sum_{j=1}^{p} \rho_j\, \Delta y_{t-j} + \sum_{j=2}^{4} \delta_j Q_{jt} + u_t, \tag{6}$$

con estadístico $\tau = \hat{\gamma}/SD(\hat{\gamma})$ y $H_0 : \gamma = 0$ (raíz unitaria) contra $H_1 : \gamma < 0$. El número de lags se elige de lo general a lo específico, exigiendo que el último rezago incluido sea significativo.

Table 1: Test ADF con valores críticos de Dickey–Fuller.

Especificación	lags	τ	1%	5%	10%	Decisión
y_t (constante + dummies)	2	-0.919	-3.51	-2.89	-2.58	No rechaza
y_t (const. + tend. + dummies)	7	-2.988	-4.04	-3.45	-3.15	No rechaza
Δy_t (constante + dummies)	1	-7.693	-3.51	-2.89	-2.58	Rechaza al 1%

En niveles no se rechaza la hipótesis nula en ninguna de las dos especificaciones: $\tau = -0.919$ frente a un valor crítico de -2.89 al 5%, y $\tau = -2.988$ frente a -3.45 cuando se incluye tendencia. Sobre la serie diferenciada, en cambio, $\tau = -7.693$ rechaza al 1% con holgura. La serie es por lo tanto $I(1)$ y corresponde $d = 1$.

Table 2: Media de y_t por trimestre (personas).

Trimestre	Media	Desv. estándar	Desvío respecto a la media general
Q1	733,111	99,062	64,691
Q2	621,741	94,270	-46,679
Q3	619,457	89,388	-48,963
Q4	698,470	96,679	30,050

El empleo es máximo en Q1 y mínimo en Q2-Q3 una brecha de 113,654 personas, cerca del 17% del nivel medio. Una regresión de Δy_t contra dummies trimestrales entrega $F(3, 77) = 242.99$ con $p < 0.001$, de modo que el patrón es sistemático y estable en toda la muestra. Se trata de estacionalidad determinística y se modela con variables dummy, en lugar de aplicar el filtro $(1 - L^4)$, que impondría una raíz unitaria estacional que los datos no respaldan.

La autocorrelación de Δy_t está dominada por la estacionalidad, $\hat{\rho}_2 = -0.84$ y $\hat{\rho}_4 = +0.86$, mientras que $\hat{\rho}_1 = -0.02$ es prácticamente nulo. Al remover las dummies trimestrales, el estadístico de Ljung–Box sobre los residuos pasa a $Q(8) = 8.06$ con $p = 0.43$, casi toda la autocorrelación era estacional. Esto anticipa que el componente ARMA será de orden bajo.

Por lo tanto, el modelo a estimar es un ARIMA$(p, 1, q)$ con dummies trimestrales y sin constante.

$$\Delta y_t \;=\; \sum_{j=2}^{4} \beta_j \, \Delta Q_{jt} \;+\; u_t, \qquad u_t \sim \text{ARMA}(p, q). \tag{7}$$

Paso 2: estimación y selección

Criterios de seleccion: **Criterios de información.** Se deben minizar los modelos por AIC y BIC. **Significancia de los parámetros estimados.** Cada coeficiente ARMA debe ser significativo al 5% y las raíces de los polinomios AR y MA deben caer fuera del círculo unitario. Si no, el modelo está sobreparametrizado y los estadísticos z no son interpretables. **Ruido blanco.** Los residuos deben pasar el test de Ljung–Box.

Table 3: Diez mejores modelos por BIC y resultado de los tres pasos. $\min|z|$ es el menor valor absoluto entre los coeficientes ARMA; LB(8) es el p-value de Ljung–Box con $m = 8 - p - q$ grados de libertad.

p	q	AIC	BIC	$\min\|z\|$	LB(8)	Paso 2	Paso 3
1	1	1859.33	1873.70	0.01	0.752	No	Si
0	2	1859.60	1873.97	2.37	0.977	Si	Si
0	0	1865.38	1874.96	–	0.428	Si	Si
2	0	1861.96	1876.33	1.64	0.699	No	Si
3	3	1857.18	1876.33	0.74	0.397	No	Si
0	1	1864.79	1876.76	3.38	0.310	Si	Si
2	4	1855.60	1877.15	0.00	0.091	No	Si
1	0	1866.24	1878.21	1.40	0.315	No	Si
1	2	1861.47	1878.24	0.27	0.964	No	Si
0	3	1861.48	1878.25	0.25	0.960	No	Si

Paso 1 El BIC deja dos candidatos, el ARIMA(1,1,1) (1873.70) y el ARIMA(0,1,2) (1873.97), separados por apenas 0.27 puntos. La diferencia es demasiado pequeña para decidir, y son los pasos siguientes los que resuelven el empate.

Paso 2 El ganador del paso 1 se cae aquí. El ARIMA(1,1,1) estima un coeficiente de media móvil cuya raíz cae exactamente sobre el círculo unitario. El modelo no es invertible, no admite representación $AR(\infty)$. De los 25 modelos estimados sobreviven solamente tres, ARIMA(0,1,2), ARIMA(0,1,1) y ARIMA(0,1,0). El resto tiene al menos un coeficiente ARMA no significativo.

Paso 3. Los tres sobrevivientes pasan también el test de Ljung -Box, de modo que el criterio de información vuelve a decidir entre ellos. El ARIMA(0,1,2) minimiza el BIC (1873.97) por debajo del ARIMA(0,1,0) (1874.96) y del ARIMA(0,1,1) (1876.76).

Table 4: Modelo seleccionado: ARIMA(0,1,2) con dummies trimestrales, sin constante. Errores estándar OPG (reportados por defecto en Stata)

Parámetro	Coeficiente	Error estándar	z	p-value
β_2 (D.q2)	-108,320.1	5,043.7	-21.48	0.0000
β_3 (D.q3)	-112,710.0	7,684.5	-14.67	0.0000
β_4 (D.q4)	-30,568.5	5,552.7	-5.51	0.0000
θ_1 (ma L1)	0.2203	0.0885	2.49	0.0128
θ_2 (ma L2)	-0.3146	0.1329	-2.37	0.0180
$\hat{\sigma}_\varepsilon$	21,673.9			

Los dos coeficientes de media móvil son significativos al 5% y las tres dummies trimestrales al 1%, de modo que el modelo no contiene parámetros redundantes.

Etapa 3: chequeo de diagnóstico

El modelo seleccionado debe generar residuos indistinguibles de ruido blanco. Se aplica el estadístico de Ljung–Box visto en clases,

$$Q_{LB} = T(T+2)\sum_{j=1}^{k}\frac{\hat{\rho}_j^2}{T-j} \;\sim\; \chi^2(m), \qquad m = k-p-q. \tag{8}$$

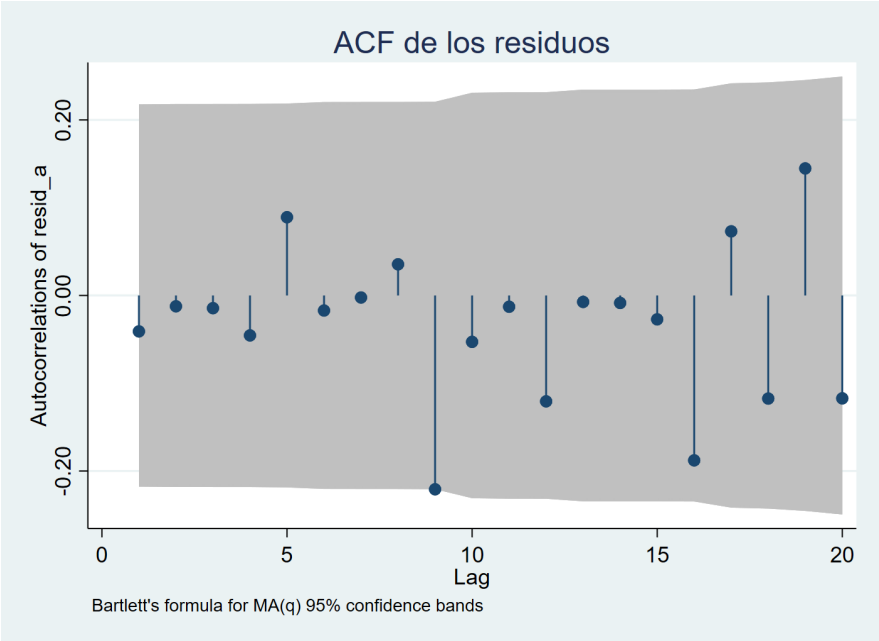


Figure 3: ACF de los residuos del modelo ARIMA(0,1,2).

Table 5: Test de Ljung-Box sobre los residuos. H_0: ruido blanco.

lags k	$m = k - p - q$	Q_{LB}	p-value
4	2	0.352	0.8386
8	6	1.198	0.9770
12	10	7.450	0.6824
16	14	11.188	0.6712

No se rechaza la hipótesis nula de ruido blanco en ningún horizonte: los p-values van de 0.67 a 0.98. Cabe señalar que el comando `wntestq` de Stata utiliza $df = k$ sin descontar los parámetros estimados; los valores de la tabla se recalcularon con $m = k - p - q$, como corresponde.

Invertibilidad. Los eigenvalues del polinomio de media móvil tienen módulo 0.682 y 0.461, ambos dentro del círculo unitario, de modo que el modelo es invertible y admite representación $AR(\infty)$. Esta condición es necesaria para que el Forecast se exprese en función de la historia observada.

Etapa 4: Forecast 2026q3–2040q4

Table 6: Forecast 2026q3–2040q4 (trimestres seleccionados). Personas.

Trimestre	h	Forecast	Error estándar	LI 95%	LS 95%	Ancho IC
2026q3	1	511,391	21,674	468,910	553,872	84,962
2026q4	2	583,779	34,195	516,758	650,801	134,043
2027q1	3	614,348	39,429	537,067	691,628	154,560
2027q2	4	506,028	44,045	419,699	592,356	172,656
2027q3	5	501,638	48,221	407,124	596,152	189,028
2027q4	6	583,779	52,064	481,734	685,824	204,090
2031q2	20	506,028	90,030	329,568	682,487	352,919
2036q2	40	506,028	125,747	259,563	752,492	492,928
2040q1	55	614,348	146,944	326,338	902,357	576,019
2040q2	56	506,028	148,249	215,459	796,596	581,137
2040q3	57	501,638	149,543	208,533	794,742	586,209
2040q4	58	583,779	150,826	288,160	879,398	591,238

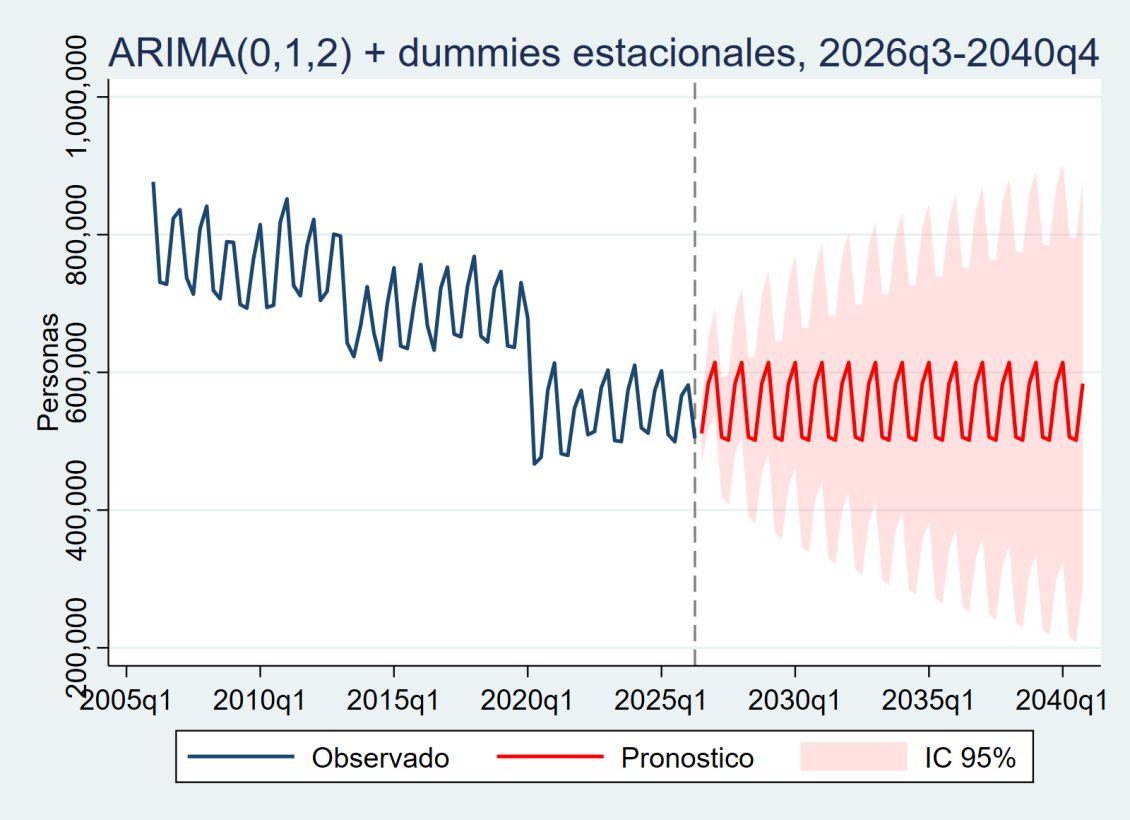


Figure 4: Forecast 2026q3–2040q4 con intervalos de confianza al 95%.

b)

El test de Bai y Perron (1998) es un procedimiento para detectar quiebres estructurales múltiples en fechas desconocidas dentro de un modelo de regresión lineal. Se parte de un modelo con T períodos

en el que puede haber m quiebres, lo que genera $m+1$ regímenes.

$$y_t = x_t'\beta_j + \varepsilon_t, \qquad j = 1, \ldots, m+1. \tag{9}$$

A diferencia del test de Chow, donde la fecha del quiebre es fija y conocida, aquí se buscan simultáneamente el número de quiebres y sus ubicaciones, minimizando la suma de cuadrados de los residuos sobre todas las particiones posibles del período muestral.

$$SSR(\beta \mid \{T\}) \;=\; \sum_{j=1}^{m+1} \left(\sum_{t=T_j}^{T_{j+1}-1} \left(y_t - x_t'\hat{\beta}_j\right)^2 \right). \tag{10}$$

El empleo agrícola tiene una estacionalidad determinística muy marcada. Si se dejara dentro del error, la suma de cuadrados de (10) estaría dominada por el ciclo trimestral y no por los cambios de nivel que el test busca detectar. Siguiendo el procedimiento en dos pasos visto en clases. Primero se remueve la estacionalidad, después se modela la dinámica se trabaja sobre la serie desestacionalizada

$$z_t \;=\; y_t - \sum_{j=1}^{4} \hat{\delta}_j Q_{jt} \;+\; \bar{y}, \tag{11}$$

donde los $\hat{\delta}_j$ son las medias trimestrales estimadas por MCO.

Table 7: Medias estacionales removidas (personas).

Trimestre	$\hat{\delta}_j$
Q1	733,111
Q2	621,741
Q3	619,457
Q4	698,470

Con esta transformación el único regresor del modelo es una constante, $x_t = 1$, de modo que β_j es simplemente la media del régimen j y un quiebre corresponde a un cambio de nivel. Sin un tamaño mínimo de régimen la minimización es degenerada, un segmento formado por una sola observación tiene $SSR = 0$, de modo que el óptimo consistiría en partir la muestra en segmentos unitarios. Se impone $h = 12$ trimestres (tres años), aproximadamente el 15% de la muestra, que es el trimming habitual en esta literatura.

Table 8: Minimización global de la SSR para cada número de quiebres. SSR en miles de millones; reducción respecto de $m = 0$.

m	SSR (10^9)	Reducción (%)	BIC	LWZ	Fechas estimadas
0	703.404	–	22.9262	22.9669	–
1	112.326	84.0	21.1992	21.3216	2019q4
2	28.870	95.9	19.9480	20.1529	2013q1, 2020q1
3	25.542	96.4	19.9330	20.2210	2008q4, 2013q1, 2020q1
4	23.585	96.6	19.9608	20.3326	2008q4, 2013q1, 2016q1, 2019q4
5	23.416	96.7	20.0611	20.5174	2008q4, 2013q1, 2016q1, 2019q4, 2023q1

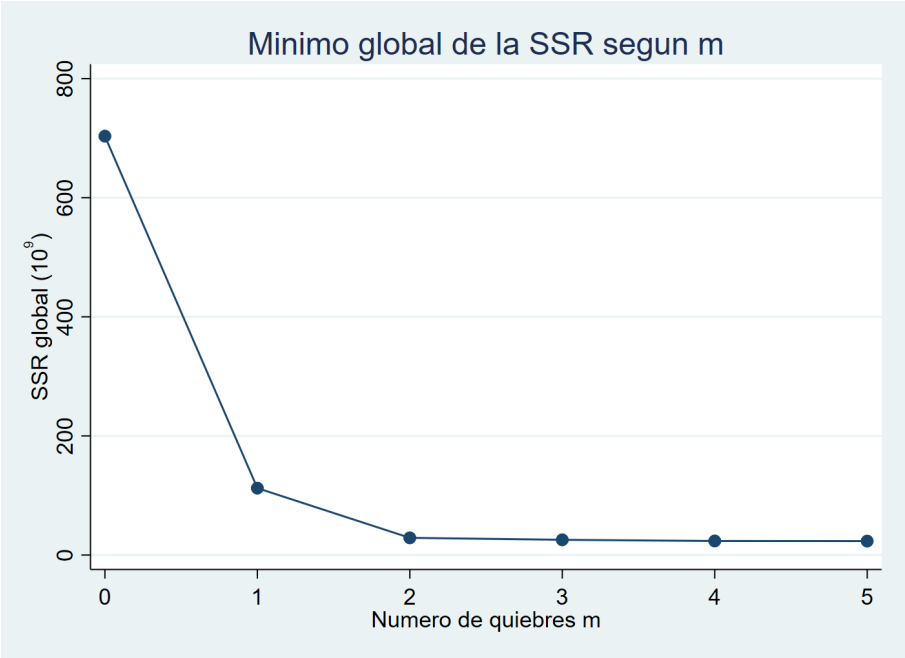


Figure 5: Mínimo global de la suma de cuadrados según el número de quiebres.

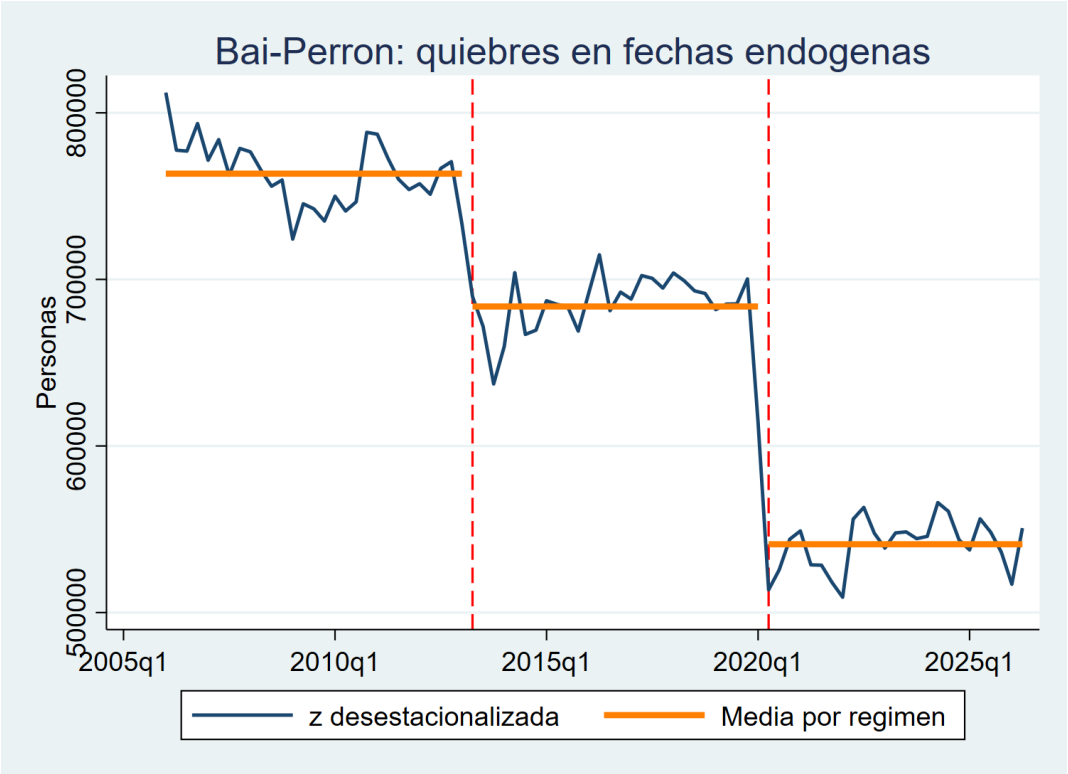


Figure 6: Serie desestacionalizada, quiebres estimados y media de cada régimen.

c)

El test de Chow evalúa si los parámetros de un modelo cambian en una fecha fija y conocida de antemano. Esa es precisamente la diferencia con el procedimiento de la parte Bai-Perron estima las fechas de forma endógena, mientras que Chow las toma como dadas. Aquí las fechas provienen de la minimización global de la suma de cuadrados, de modo que ambos tests son complementarios uno encuentra los candidatos y el otro los contrasta formalmente.

Se estima un $ARMA(p, q)$ con una muestra de tamaño T y se sospecha un quiebre inmediatamente después de la fecha m. El test compara tres estimaciones del mismo modelo:

1. Muestra total $1, \ldots, T$: $y_t = \alpha_0 + \alpha_1 y_{t-1} + \cdots + \alpha_p y_{t-p} + \varepsilon_t + \beta_1 \varepsilon_{t-1} + \cdots + \beta_q \varepsilon_{t-q}$, de donde se obtiene SSR.
2. Submuestra 1, $1, \ldots, m$: mismo modelo con coeficientes $\alpha_{10}, \ldots, \beta_{1q}$, de donde se obtiene SSR_1.
3. Submuestra 2, $m+1, \ldots, T$: mismo modelo con coeficientes $\alpha_{20}, \ldots, \beta_{2q}$, de donde se obtiene SSR_2.

La hipótesis nula es que todos los coeficientes coinciden entre ambos subperíodos, es decir, que no hay quiebre estructural.

$$H_0 : \ \alpha_{10} = \alpha_{20}; \ \ \alpha_{11} = \alpha_{21}; \ \ldots; \ \alpha_{1p} = \alpha_{2p}; \ \ \beta_{11} = \beta_{21}; \ \ldots; \ \beta_{1q} = \beta_{2q}, \tag{12}$$

y el estadístico de prueba es

$$F \ = \ \frac{(SSR - SSR_1 - SSR_2)/n}{(SSR_1 + SSR_2)/(T - 2n)} \ \sim \ F(n, \ T - 2n), \tag{13}$$

donde n es el número de parámetros estimados ($n = p + q + 1$ si el modelo incluye intercepto, $p + q$ si no).

La intuición es directa: si no hay quiebre estructural, estimar por separado no mejora el ajuste, de modo que $SSR_1 + SSR_2 \approx SSR$, el numerador de (13) se acerca a cero y no se rechaza H_0.

Table 9: Selección del $ARMA(p, q)$ de referencia para z_t.

p	q	AIC	BIC
1	0	1890.26	1897.48
1	1	1890.34	1899.97
3	0	1888.88	1900.91
2	1	1889.96	1902.00
1	3	1890.44	1904.88
2	2	1890.44	1904.88

El BIC selecciona un $AR(1)$ con intercepto. Por lo tanto

$$n = p + q + 1 = 1 + 0 + 1 = 2, \qquad \text{grados de libertad} = (n, \ T - 2n) = (2, \ 78), \tag{14}$$

con valores críticos $F_{0.95}(2, 78) = 3.114$ y $F_{0.99}(2, 78) = 4.888$.

Se evalúan las dos fechas obtenidas en la parte b), 2013q1 y 2020q1, y además 2008q4, que es la fecha adicional que aparecía con $m = 3$ y que se descartó y la incluimos para contrastar esa decisión.

Table 10: Test de Chow. Sumas de cuadrados en miles de millones. $F(2, 78)$, con $F_{0.95} = 3.114$ y $F_{0.99} = 4.888$.

Quiebre	SSR	SSR_1	SSR_2	F	VC 5%	VC 1%	p-value	Decisión
2008q4	43.243	1.395	39.015	2.734	3.114	4.888	0.071202	No rechaza
2013q1	43.243	6.537	32.060	4.695	3.114	4.888	0.011881	Rechaza al 5%
2020q1	43.243	25.996	4.332	16.608	3.114	4.888	0.000001	Rechaza al 1%

Los dos quiebres obtenidos en b) se confirman. En 2020q1 el estadístico es $F = 16.608$. En 2013q1 el estadístico es $F = 4.695$, que supera el valor crítico al 5%). Es un quiebre real pero claramente de menor magnitud, lo que es coherente con lo estimado en la parte b).

La fecha descartada se comporta como debe. En 2008q4 el estadístico es $F = 2.734$, no se rechaza la hipótesis nula. Esto respalda de forma independiente la decisión tomada en la parte b) de no considerar el tercer quiebre, que el BIC sugería pero que caía exactamente en el largo mínimo de régimen.

d)

Las partes (b) y (c) establecieron que la serie no tiene parámetros constantes, hay dos quiebres, en 2013q1 y 2020q1. La parte a), modeló las 82 observaciones como un único proceso, tratando la caída acumulada como una sucesión de shocks permanentes. Esta parte rehace el Forecast tomando los quiebres.

El último quiebre que tenemos define el régimen vigente, que va desde 2020q2 hasta el final de la muestra. Sobre esa submuestra se aplica de nuevo la metodología Box-Jenkins completa. El supuesto central es que el régimen vigente se mantiene durante todo el horizonte de proyección, es decir no existirán otras caídas como hubo en 2020 o 2013.

Etapa 1: identificación sobre el régimen

Table 11: Identificación sobre la submuestra 2020q2–2026q2.

	Valor
Observaciones del regimen	25
F de estacionalidad	65.58
p-value	0.0000
ADF: τ (con 1 rezago)	-3.678
Valor critico DF al 5%	-3.00

La estacionalidad sigue siendo muy marcada ($F = 65.58$), de modo que el modelo mantiene las cuatro dummies trimestrales. Aplicando el ADF sobre la submuestra desestacionalizada, con selección de lags de lo general a lo específico, se obtiene $\tau = -3.678$ con un rezago, contra un valor crítico de Dickey-Fuller de aproximadamente -3.00 al 5% para este tamaño de muestra. Se rechaza la raíz unitaria.

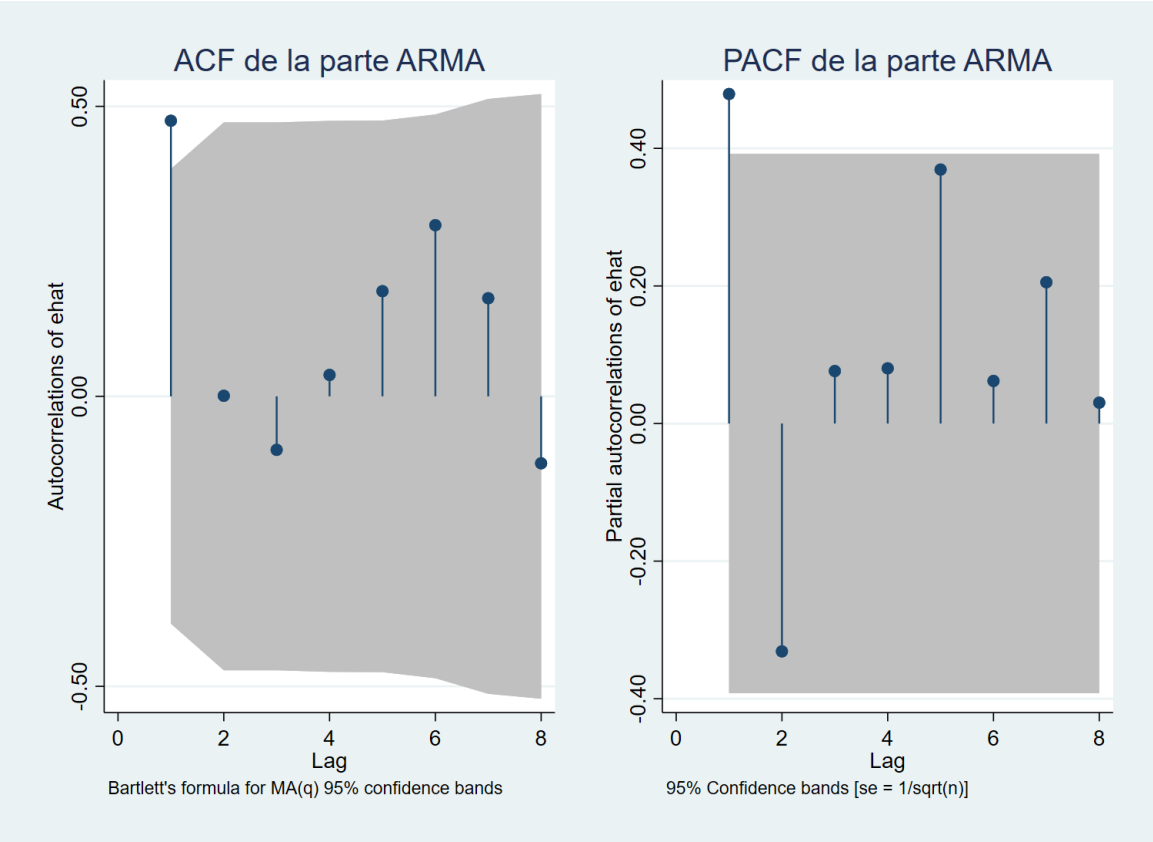


Figure 7: ACF y PACF de la parte ARMA (residuos de las dummies estacionales) en el régimen 2020q2–2026q2.

La ACF cae en el primer rezago a valores dentro de las bandas a partir del segundo, y la PACF muestra un pico en el primer rezago y nada después. Esto sugiere un solo rezago.

Table 12: Selección del $ARMA(p^*, q^*)$ del régimen. Los módulos son los de los eigenvalues, de modo que la condición de admisibilidad es que sean menores que 1. LB(8) es el p-value de Ljung–Box.

p	q	AIC	BIC	$\min\|z\|$	$\|\lambda\|_{MA}$	$\|\lambda\|_{AR}$	LB(8)	Admisible
1	1	549.07	556.38	0.18	1.000	0.057	0.693	No
0	1	549.13	556.44	0.00	1.000	–	0.785	No
0	3	548.70	557.23	0.00	1.000	–	0.056	No
2	1	550.82	559.35	0.11	1.000	0.377	0.513	No
1	2	550.97	559.50	0.19	1.000	0.806	0.524	No
0	2	551.08	559.61	0.00	1.000	–	0.692	No
2	0	551.60	560.13	1.35	–	0.644	0.756	No
1	0	553.06	560.37	3.01	–	0.587	0.317	Si

Los seis modelos con mejor BIC incluyen todos un componente de media móvil cuyo eigenvalue tiene módulo 1.000, están sobre el círculo unitario, no son invertibles y el óptimo se alcanza en la frontera del espacio de parámetros, razón por la cual su $\min|z|$ colapsa a cero. De los modelos admisibles, el de menor BIC es el **AR(1)**, con $|z| = 3.01$ para el coeficiente autorregresivo y p-value de Ljung-Box de 0.317.

Table 13: Modelo estimado sobre el régimen 2020q2–2026q2.

Parámetro	Coeficiente	Error estándar	z	p-value
ϕ_1	0.5871	0.1948	3.01	0.0026
δ_{Q1}	594,276	8,275	71.82	0.0000
δ_{Q2}	498,415	6,092	81.81	0.0000
δ_{Q3}	496,215	11,188	44.35	0.0000
δ_{Q4}	567,364	10,415	54.47	0.0000
$\hat{\sigma}_\varepsilon$	12,014			

El modelo es entonces

$$y_t = \delta_{Q(t)} + u_t, \qquad u_t = 0.5871\, u_{t-1} + \varepsilon_t, \qquad \hat{\sigma}_\varepsilon = 12{,}014, \tag{15}$$

donde $\delta_{Q(t)}$ es el nivel del trimestre correspondiente. El orden y los coeficientes son distintos de los de la parte a), que era un $ARIMA(0,1,2)$ con $\hat{\sigma}_\varepsilon = 21{,}674$, en este nuevo modelo la desviación estándar del error cae casi a la mitad al estimar solo dentro del régimen.

Table 14: Ljung–Box sobre los residuos del modelo del régimen.

lags k	$m = k - p - q$	Q_{LB}	p-value
4	3	4.059	0.2552
8	7	8.183	0.3167
12	11	9.407	0.5844

No se rechaza ruido blanco en ningún horizonte, con p-values entre 0.26 y 0.58. El eigenvalue autorregresivo tiene módulo 0.587, cómodamente dentro del círculo unitario, de modo que el proceso es estacionario y el Forecast converge.

Table 15: Forecast 2026q3–2040q4 con el modelo del régimen. Personas.

Trimestre	h	Forecast	Error estándar	LI 95%	LS 95%	Ancho IC
2026q3	1	499,508	12,014	475,961	523,055	47,094
2026q4	2	569,298	13,931	541,993	596,603	54,610
2027q1	3	595,411	14,533	566,925	623,896	56,971
2027q2	4	499,081	14,735	470,200	527,962	57,762
2031q2	20	498,415	14,840	469,328	527,502	58,174
2036q2	40	498,415	14,840	469,328	527,502	58,174
2040q1	55	594,276	14,840	565,189	623,363	58,174
2040q2	56	498,415	14,840	469,328	527,502	58,174
2040q3	57	496,215	14,840	467,128	525,302	58,174
2040q4	58	567,364	14,840	538,277	596,451	58,174

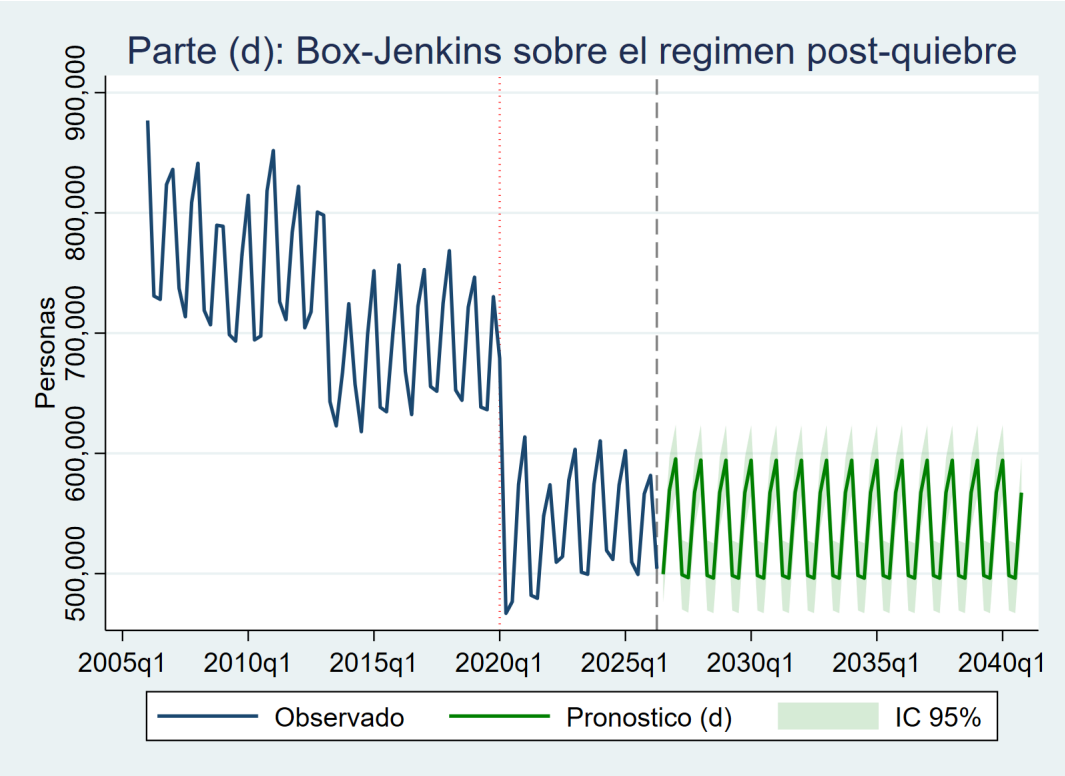


Figure 8: Forecast 2026q3–2040q4 estimado sobre el régimen post-quiebre.

Lo relevante es que el error estándar deja de crecer a diferencia del modelo en a), parte en 12,014 y se estabiliza en 14,840 a partir de unos cinco trimestres. El ancho del intervalo se estanca en 58,174 personas y no vuelve a moverse. A diferencia de la parte (a), aquí la suma es una serie geométrica convergente porque $|\phi_1| < 1$. Cuando $j \to \infty$,

$$Var(e_t(j)) \longrightarrow \frac{\sigma_\varepsilon^2}{1-\phi_1^2} = \frac{12{,}014^2}{1-0.5871^2}, \qquad \text{es decir} \qquad \sqrt{Var} \to 14{,}840. \tag{16}$$

Los Forecasts son parecidos, pero la diferencia está en la incertidumbre. En a) el ancho del intervalo crece sin cota. En d) se estabiliza en 58,174 y ahí se queda, pero es importante entender que está sujeto a supuestos este resultado. El Forecast proyecta a catorce años sin nuevos quiebres siendo que tenemos conocimiento que en la serie tuvimos dos quiebres. Tambien es importante mencionar que el modelo se estima con 25 observaciones y seis parámetros unicamente. Los coeficientes estacionales son muy precisos, pero el ϕ_1 tiene un error estándar de 0.195 sobre una estimación de 0.587.